Instituto INFNET

Shaiane Alves Tonin

Projeto da Disciplina

Fundamentos de Machine Learning com Scikit-Learn

Turim
2026

Introdução 2
Contexto empresarial 3
Uso do Machine Learning 3
Descrição do dataset 3
Características principais 4
Features 4
Target feature 4
Features utilizadas 5
Principais problemáticas do conjunto de dados 5
Modelo baseline: Classificador Linear com Perceptron 6
Análise exploratória 6
Transformações 7
Escalonamento das variáveis numéricas 7
Tratamento da assimetria em Balance 8
Codificação de variáveis categóricas 8
Variáveis binárias 8
Treinando o modelo 8
Resultados 9
Avaliação do modelo sem a variável complain 10
Interpretação do modelo 11
Limitações do Perceptron 11
Discussão Aplicada 11
Modelo com Árvore de Decisão 12
Avaliação do modelo 13
Interpretação da estrutura da árvore 13
Risco de overfitting 14
Comparação com o modelo baseline 14
Discussão aplicada 14
Validação cruzada e otimização de hiperparâmetros 15
Comparação entre a Árvore Original e o Modelo Otimizado 15
Robustez do desempenho 16

Variação das métricas entre os folds 16
Impacto da regularização na estrutura da árvore 16
Generalização do modelo 16
Interpretabilidade do modelo 17
Mínimos locais no treinamento de árvores 17
Discussão Aplicada 17
Modelo Ensemble: Random Forest 18
Validação cruzada e busca de hiperparâmetros 18
Avaliação do modelo 18
Importância das variáveis 19
Comparação com os modelos anteriores 19
Complexidade e custo computacional 20
Discussão aplicada 20

Introdução

Contexto empresarial

Instituições financeiras operam em mercados competitivos, nos quais a retenção de clientes representa um fator fundamental para a sustentabilidade e o crescimento do negócio. A perda de clientes, frequentemente denominada *customer churn*, resulta na redução direta de receitas e pode aumentar significativamente os custos associados à aquisição de novos clientes.

Nesse contexto, a capacidade de prever antecipadamente quais clientes apresentam maior probabilidade de encerrar sua relação com o banco permite que a instituição implemente estratégias de retenção direcionadas, como ofertas personalizadas, melhorias nos serviços ou ajustes nas condições contratuais.

Uso do Machine Learning

A decisão de um cliente de encerrar sua relação com um banco não depende de um único fator isolado, mas sim de uma combinação complexa de variáveis relacionadas ao perfil do cliente, às suas características financeiras e ao seu comportamento de utilização dos serviços bancários. Além disso, a quantidade de dados disponíveis pode ser significativa, tornando inviável a análise manual ou a construção de regras heurísticas simples capazes de capturar todos os padrões relevantes, bem como a identificação de relações complexas apenas por meio de análises estatísticas tradicionais.

Nesse contexto, o uso de modelos de *machine learning* supervisionado torna-se uma abordagem apropriada, pois permite identificar estruturas e padrões complexos nos dados, apoiando processos de tomada de decisão.

Descrição do dataset

O dataset utilizado neste projeto é o Bank Customer Churn Dataset, disponível publicamente na plataforma Kaggle.

Ele contém informações sobre clientes de uma instituição financeira e diversas características relacionadas ao perfil demográfico, histórico bancário e comportamento financeiro dos clientes.

Características principais

- Aproximadamente 10.000 observações
- 18 features totais
- Predominância de variáveis numéricas discretas e contínuas, com duas variáveis categóricas nominais e uma ordinal, e três variáveis binárias.

Features

- **RowNumber:** número do registro no dataset, utilizado apenas como identificador.
- **CustomerId:** identificador único do cliente.
- **Surname:** sobrenome do cliente.
- **CreditScore:** pontuação de crédito do cliente.
- **Geography:** país do cliente.
- **Gender:** gênero do cliente.
- **Age:** idade do cliente.
- **Tenure:** número de anos que o cliente mantém relacionamento com o banco.
- **Balance:** saldo da conta do cliente.
- **NumOfProducts:** quantidade de produtos bancários utilizados pelo cliente.
- **HasCrCard:** indica se o cliente possui cartão de crédito.
- **IsActiveMember:** indica se o cliente é um usuário ativo dos serviços do banco.
- **EstimatedSalary:** estimativa de renda do cliente.
- **Exited:** variável-alvo que indica se o cliente deixou o banco ou permaneceu como cliente.
- **Complain:** indica se o cliente registrou alguma reclamação.
- **SatisfactionScore:** pontuação de satisfação atribuída pelo cliente após a resolução de uma reclamação.
- **Card Type:** tipo de cartão de crédito utilizado pelo cliente.
- **Points Earned:** quantidade de pontos acumulados pelo cliente por meio do uso do cartão de crédito.

Target feature

A variável-alvo utilizada neste projeto é Exited, que indica se um cliente deixou de utilizar os serviços da instituição financeira.

O problema é formulado como classificação binária, pois o objetivo do modelo é prever uma entre duas possíveis classes mutuamente exclusivas: clientes que irão encerrar sua relação com o banco e clientes que continuarão utilizando os serviços da instituição.

Essa formulação permite que a instituição financeira identifique clientes com maior probabilidade de saída e implemente estratégias de retenção direcionadas, contribuindo para a redução da taxa de churn e para a melhoria da gestão do relacionamento com os clientes.

Features utilizadas

Antes da construção do modelo, algumas variáveis foram removidas do dataset por não possuírem valor preditivo. As variáveis **RowNumber**, **CustomerId** e **Surname** possuem apenas função identificadora, servindo exclusivamente para distinguir registros ou clientes específicos. Como essas variáveis não apresentam relação com o comportamento financeiro do cliente ou com a decisão de encerrar sua relação com o banco, sua inclusão no modelo poderia introduzir ruído e não contribuir para a capacidade preditiva do classificador.

Após essa etapa de limpeza, foram mantidas apenas as variáveis potencialmente relevantes para a previsão do churn. O conjunto final de features inclui variáveis:

- **numéricas contínuas:** *CreditScore*, *Age*, *Balance*, *EstimatedSalary, Point Earned*, que descrevem características financeiras e demográficas dos clientes e têm papel central no modelo, pois permitem capturar diferenças graduais entre os clientes.
- **numéricas discretas**: NumOfProducts, SatisfactionScore e Tenure.
- **categóricas nominais:** *Geography* e *Gender,* foram incluídas no modelo porque representam características qualitativas relevantes dos clientes que podem influenciar a probabilidade de churn, permitindo capturar diferenças de comportamento entre grupos de clientes.
- **categóricas ordinais**: CardType
- **binarias**: HasCrCard, IsActiveMmember, Complain

Principais problemáticas do conjunto de dados

O problema de previsão de customer churn apresenta alguns desafios típicos. Um dos principais é o desbalanceamento entre classes, já que a maioria dos clientes permanece no banco enquanto apenas uma parcela menor realiza churn. No dataset utilizado, aproximadamente 80% dos clientes permanecem ativos e cerca de 20% deixam a instituição, o que pode dificultar a capacidade do modelo de identificar corretamente a classe minoritária.

Outro desafio relevante está relacionado ao custo assimétrico dos erros. Em contextos de negócios, classificar erroneamente um cliente que irá cancelar o serviço como um cliente estável pode gerar perdas financeiras, pois a empresa perde a oportunidade de aplicar estratégias de retenção. Por outro lado, classificar um cliente estável como potencial churn pode levar a custos desnecessários em ações de retenção.

Além disso, modelos utilizados nesse tipo de aplicação frequentemente precisam apresentar certo nível de explicabilidade, permitindo que gestores compreendam quais fatores influenciam a decisão do modelo.

Por fim, os dados podem conter ruído ou variáveis altamente correlacionadas com o evento de churn, o que pode influenciar artificialmente o desempenho do modelo.

Modelo baseline: Classificador Linear com Perceptron

Nesta etapa foi construído um modelo baseline utilizando o Perceptron, um classificador linear clássico utilizado em problemas de classificação binária. O Perceptron foi escolhido como modelo inicial porque permite compreender de forma clara a geometria da decisão do modelo e estabelecer um ponto de comparação para modelos mais complexos.

Análise exploratória

A distribuição das principais variáveis numéricas foi analisada por meio de histogramas, permitindo observar padrões de dispersão, assimetria e possíveis valores extremos.

A variável **CreditScore** apresenta uma distribuição aproximadamente normal, com maior concentração de valores próximos ao intervalo entre 600 e 700 pontos.

A variável **Age** apresenta uma distribuição aproximadamente unimodal, com maior concentração entre 30 e 45 anos. Observa-se uma cauda à direita associada a clientes mais idosos, indicando leve assimetria positiva. Apesar disso, a distribuição permanece relativamente consistente com o perfil demográfico esperado para clientes bancários.

A variável **Tenure** apresenta uma distribuição relativamente uniforme ao longo do intervalo entre 0 e 10 anos, com frequências semelhantes para a maioria dos valores.

A variável **Balance** apresenta uma forte concentração de observações no valor zero, indicando que uma parcela significativa dos clientes não possui saldo em conta. Além disso, os demais valores se distribuem em torno de aproximadamente 100.000, gerando uma distribuição altamente assimétrica.

A variável **NumOfProducts** apresenta uma distribuição discreta, com predominância de clientes possuindo um ou dois produtos financeiros.

A variável **EstimatedSalary** apresenta uma distribuição aproximadamente uniforme ao longo de seu intervalo de valores, indicando que os salários estimados dos clientes estão relativamente bem distribuídos entre os diferentes níveis de renda. Não foram observadas concentrações anormais ou evidências claras de valores extremos.

A variável **Satisfaction Score** apresenta uma distribuição discreta entre os valores 1 e 5, com frequências relativamente semelhantes em todas as categorias.

Por fim, variável **Point Earned** apresenta uma distribuição relativamente uniforme ao longo do intervalo observado, sugerindo que os pontos acumulados pelos clientes estão distribuídos de forma relativamente equilibrada entre os diferentes níveis de uso do cartão.

Transformações

Com base na análise exploratória, algumas transformações foram feitas para melhorar o modelo.

Escalonamento das variáveis numéricas

As variáveis numéricas do dataset apresentam escalas muito diferentes. Por esse motivo, foi aplicado o StandardScaler às variáveis numéricas: CreditScore, Age, Tenure, Balance, EstimatedSalary, Point Earned e Satisfaction Score.

Esse método padroniza os dados para média zero e desvio padrão unitário, sendo particularmente adequado para modelos lineares como o Perceptron. Além disso, a análise exploratória indicou ausência de outliers extremos, tornando desnecessário o uso de métodos mais robustos como o RobustScaler.

Tratamento da assimetria em Balance

A variável Balance apresenta uma assimetria devido à elevada concentração de valores iguais a zero. Embora isso não represente necessariamente um erro nos dados, essa característica pode dificultar o aprendizado de modelos lineares, pois distribuições assimétricas podem influenciar de forma desproporcional os coeficientes do modelo.

Uma possível abordagem para reduzir essa assimetria seria a aplicação de uma transformação logarítmica. No entanto, essa transformação não pode ser aplicada diretamente devido à presença de valores iguais a zero. Dessa forma, além da padronização das variáveis numéricas, foi aplicada a transformação Yeo-Johnson, que permite lidar com valores nulos e tem como objetivo aproximar a distribuição da variável de uma forma mais próxima da normalidade.

Codificação de variáveis categóricas

As variáveis categóricas Geography e Gender foram transformadas para formato numérico por meio do One-Hot Encoding, permitindo que sejam utilizadas pelo modelo. Enquanto a variável Card Type foi codificada de forma ordinal, pois os diferentes tipos de cartão representam níveis hierárquicos de relacionamento do cliente com o banco. Dessa forma, as categorias *Silver*, *Gold*, *Platinum* e *Diamond* foram convertidas para valores numéricos crescentes, preservando essa relação de ordem.

Variáveis binárias

As variáveis HasCrCard, IsActiveMember e Complain são variáveis binárias que indicam a presença ou ausência de determinadas características. Como já estão representadas numericamente por valores 0 e 1, elas foram utilizadas diretamente no modelo sem necessidade de transformação adicional.

Treinando o modelo

A divisão do dataset em conjuntos de treino e teste foi realizada utilizando **Exited** como variável alvo (*y*) e as demais variáveis do dataset como **features explicativas (x)**.

Os parâmetros utilizados foram:

- test_size = 0.3: 30% dos dados utilizados para teste, enquanto os 70% restantes utilizados para treinamento do modelo.
- stratify = y: garante que a proporção das classes da variável alvo seja preservada tanto no conjunto de treino quanto no de teste.
- random_state = 25: define um valor aleatório fixo, garantindo que a divisão dos dados possa ser reproduzida em execuções futuras do código.

Após a divisão do dataset em conjuntos de treino e teste, foi realizada uma verificação da distribuição da variável alvo para garantir que a proporção de classes foi preservada. No conjunto de dados original, aproximadamente 79,6% dos clientes permaneceram no banco e 20,4% dos clientes deixaram a instituição.

Após o *train-test split*, observou-se que essa proporção foi mantida de forma muito aproximada tanto no conjunto de treino quanto no conjunto de teste. No conjunto de treino, a proporção de clientes que permaneceram no banco foi de aproximadamente 79,61%, enquanto 20,39% representam clientes que saíram. De forma semelhante, no conjunto de teste, cerca de 79,63% dos clientes permaneceram e 20,37% deixaram o banco.

Esses resultados indicam que a divisão dos dados preservou adequadamente a distribuição da variável alvo.

Resultados

Após o treinamento do classificador Perceptron, o modelo foi avaliado utilizando as métricas Accuracy, Precision, Recall e F1-score nos conjuntos de treinamento e teste.

No conjunto de treinamento, o modelo apresentou desempenho extremamente elevado, com accuracy próxima de 1.00. Para a classe 0 (clientes que permaneceram no banco), as métricas de precision, recall e F1-score foram iguais a 1.00. Para a classe 1 (clientes que deixaram o banco), os valores também foram muito altos, com precision de 0.99, recall de 1.00 e F1-score de 0.99.

Resultados semelhantes foram observados no conjunto de teste, onde a accuracy também foi próxima de 1.00, indicando que o modelo manteve desempenho consistente entre os dados de treinamento e teste.

Entretanto, resultados tão elevados para um modelo linear simples como o Perceptron são incomuns em problemas reais de churn. Isso pode indicar que algumas variáveis do dataset possuem alto poder discriminatório. Em particular, a variável Complain pode estar fortemente associada ao churn, funcionando quase como um indicador direto de cancelamento.

Avaliação do modelo sem a variável complain

Para verificar a possível influência da variável Complain no desempenho do modelo, foi realizado um novo treinamento do classificador Perceptron após a remoção dessa variável do conjunto de dados.

No conjunto de treinamento, o modelo apresentou accuracy de aproximadamente 0.75. Para a classe dos clientes que permaneceram no banco, o modelo apresentou precision de 0.83, recall de 0.86 e F1-score de 0.85, indicando boa capacidade de identificar clientes que não cancelaram o serviço. No entanto, para a classe de clientes que realizaram churn, o desempenho foi significativamente inferior, com precision de 0.37, recall de 0.32 e F1-score de 0.34.

Resultados semelhantes foram observados no conjunto de teste, onde a accuracy foi de aproximadamente 0.76. Para a classe 0, as métricas permaneceram relativamente altas (precision de 0.84, recall de 0.86 e F1-score de 0.85), enquanto para a classe 1 os valores permaneceram baixos (precision de 0.39, recall de 0.34 e F1-score de 0.36).

A redução significativa do desempenho em comparação com o modelo anterior indica que a variável Complain possuía forte capacidade preditiva em relação ao churn. Isso sugere que o alto desempenho observado anteriormente pode ter sido influenciado por uma variável altamente correlacionada com o evento de cancelamento.Além disso, observa-se que o modelo apresenta maior dificuldade em identificar corretamente a classe 1, o que é comum em problemas com classes desbalanceadas, onde a maioria

das observações pertence à classe dominante. Nesse caso, aproximadamente 80% dos clientes permanecem no banco, enquanto apenas cerca de 20% realizam churn.

Esses resultados reforçam o papel do Perceptron como modelo baseline, permitindo estabelecer um ponto de comparação inicial para avaliar modelos mais complexos nas etapas posteriores do projeto.

Interpretação do modelo

Uma das vantagens do Perceptron é sua interpretabilidade geométrica. Os coeficientes aprendidos pelo modelo indicam a contribuição de cada variável na função de decisão. Valores positivos aumentam a probabilidade de classificação na classe positiva, enquanto valores negativos contribuem para a classificação na classe negativa. O bias representa o termo constante da equação e determina o deslocamento da fronteira de decisão no espaço das features.

Juntos, os coeficientes e o bias definem um hiperplano separador no espaço das variáveis. Esse hiperplano divide o espaço das features em duas regiões correspondentes às classes do problema.

Limitações do Perceptron

Apesar de sua simplicidade e interpretabilidade, o Perceptron possui algumas limitações importantes. O modelo assume que as classes são linearmente separáveis, o que raramente ocorre em problemas reais. Quando os dados apresentam relações não lineares, o modelo pode não conseguir representar adequadamente os padrões presentes no dataset.

Além disso, o Perceptron é sensível a ruído e outliers, pois pontos extremos podem influenciar significativamente a posição da fronteira de decisão.

Por fim, modelos lineares simples como o Perceptron podem apresentar underfitting, ou seja, capacidade limitada de capturar estruturas complexas nos dados.

Dessa forma, o uso do Perceptron nesta etapa permite estabelecer um baseline

simples e interpretável, que servirá como referência para comparar o desempenho de modelos mais sofisticados nas etapas seguintes do projeto.

Discussão Aplicada

De forma geral, o modelo baseline baseado no Perceptron demonstra que é possível identificar padrões associados ao churn utilizando um classificador linear simples. No entanto, apesar de sua utilidade como ponto de partida, sua aplicação direta em um contexto real apresenta limitações. O modelo possui capacidade limitada para capturar relações complexas entre as variáveis e pode ter dificuldade em representar padrões não linearmente separáveis presentes em dados reais de comportamento de clientes.

Embora o modelo tenha apresentado métricas de desempenho muito elevadas em algumas configurações, esses resultados devem ser interpretados com cautela. No contexto empresarial, certas variáveis podem estar diretamente associadas ao evento de churn. Por exemplo, é esperado que clientes que registram reclamações estejam mais propensos a cancelar o serviço. Nesse caso, o modelo pode estar apenas aprendendo uma relação já evidente, o que reduz o valor prático da previsão. Em outras palavras, boas métricas não necessariamente significam um modelo útil para tomada de decisão, especialmente quando a informação utilizada já indica claramente o comportamento do cliente.

Para investigar esse efeito, foi realizado um novo experimento removendo a variável Complain do conjunto de dados. Nesse cenário, o desempenho do modelo apresentou uma redução significativa. Esse resultado sugere que a variável Complain possuía forte capacidade preditiva e estava exercendo grande influência no modelo original. Ao removê-la, o problema torna-se mais desafiador e mais próximo de uma situação real de previsão antecipada de churn.

Do ponto de vista operacional, embora modelos lineares apresentem boa interpretabilidade e baixo custo computacional, sua simplicidade pode reduzir a precisão das previsões em cenários mais complexos. Por esse motivo, possíveis melhorias incluem o uso de modelos mais robustos, como árvores de decisão, métodos ensemble ou máquinas de vetor de suporte, que possuem maior capacidade de capturar relações não lineares entre as variáveis. Além disso, técnicas adicionais de ajuste de hiperparâmetros e validação cruzada podem contribuir para melhorar a generalização do modelo e obter resultados mais confiáveis em aplicações reais.

Modelo com Árvore de Decisão

Nesta etapa foi treinado um modelo de Árvore de Decisão para o mesmo problema de classificação de churn, utilizando o mesmo conjunto de dados e o mesmo processo de pré-processamento aplicado no modelo baseline. A variável Complain foi removida da análise, pois foi identificada anteriormente como uma variável com forte associação direta ao churn, o que poderia distorcer a avaliação do modelo.

A árvore foi treinada utilizando os parâmetros padrão do DecisionTreeClassifier, sem restrições adicionais de profundidade ou regularização. Após o treinamento, observou-se que a árvore atingiu profundidade igual a 26 e 928 folhas, indicando uma estrutura bastante complexa e altamente flexível.

Avaliação do modelo

No conjunto de treinamento, o modelo apresentou desempenho perfeito, com accuracy igual a 1.00 e valores de precision, recall e F1-score também iguais a 1.00 para ambas as classes. Esse resultado indica que a árvore foi capaz de memorizar completamente os dados de treinamento.

No entanto, no conjunto de teste, o desempenho foi significativamente inferior. O modelo apresentou accuracy de aproximadamente 0.80, com desempenho desigual entre as classes. Para a classe 0, o modelo apresentou precision de 0.88, recall de 0.86 e F1-score de 0.87, indicando bom desempenho na identificação dessa classe majoritária. Já para a classe 1 (clientes que realizam churn), o desempenho foi consideravelmente menor, com precision de 0.50, recall de 0.54 e F1-score de 0.52.

Interpretação da estrutura da árvore

A grande profundidade da árvore e o elevado número de folhas indicam que o modelo criou muitas regras específicas para separar as observações do conjunto de treinamento. Cada caminho da raiz até uma folha representa uma sequência de decisões baseadas em valores de corte das variáveis, como por exemplo limites em variáveis financeiras ou demográficas.

Embora essa flexibilidade permita capturar relações não lineares entre as variáveis, ela também aumenta significativamente a complexidade do modelo. Árvores muito

profundas tendem a criar regras altamente específicas para os dados de treinamento, o que reduz sua capacidade de generalização para novos dados.

Risco de overfitting

A diferença entre o desempenho no conjunto de treinamento (accuracy = 1.00) e no conjunto de teste (accuracy ≈ 0.80) indica um claro caso de overfitting. O modelo aprendeu padrões muito específicos do conjunto de treinamento, incluindo possíveis ruídos nos dados, o que compromete sua capacidade de generalização.

Esse comportamento é esperado em árvores de decisão treinadas sem restrições de complexidade, pois esse tipo de modelo possui alta capacidade de adaptação aos dados.

Comparação com o modelo baseline

Comparando com o modelo Perceptron, observa-se que a árvore de decisão apresenta maior capacidade de capturar relações não lineares entre as variáveis. No entanto, essa flexibilidade também aumenta o risco de overfitting quando não há controle sobre a profundidade ou o número de folhas da árvore.

Discussão aplicada

A árvore de decisão possui uma vantagem importante em um contexto empresarial: sua interpretabilidade. As regras geradas pelo modelo permitem identificar quais características dos clientes estão associadas a maior risco de churn, o que pode ajudar gestores a compreender melhor os fatores que influenciam o cancelamento e orientar estratégias de retenção.

No entanto, os resultados também indicam limitações relevantes para uma aplicação prática. A grande complexidade da árvore e a diferença de desempenho entre treino e teste sugerem que o modelo pode não generalizar bem para novos clientes. Em um ambiente empresarial, isso representa um risco, pois decisões baseadas em previsões pouco estáveis podem levar a estratégias de retenção ineficientes.

Além disso, observa-se que o modelo apresenta desempenho relativamente limitado na identificação dos clientes que realmente realizam churn, que são justamente os casos mais relevantes para o negócio. Isso reduz o valor prático do modelo, já que o

objetivo principal é identificar antecipadamente clientes com maior probabilidade de saída.

Validação cruzada e otimização de hiperparâmetros

Nesta etapa foi realizado um processo de validação cruzada e otimização de hiperparâmetros para o modelo de árvore de decisão. O objetivo dessa etapa foi reduzir o risco de overfitting observado anteriormente e obter um modelo com melhor capacidade de generalização.

Para isso, foi utilizada validação cruzada estratificada com 10 folds (StratifiedKFold), garantindo que cada subconjunto utilizado durante o treinamento mantivesse a mesma proporção entre as classes de churn e não churn. Esse procedimento permite obter uma estimativa mais robusta do desempenho do modelo, reduzindo a dependência de uma única divisão entre treino e teste.

Em seguida, foi realizada uma busca sistemática de hiperparâmetros utilizando Grid Search. Essa abordagem avalia todas as combinações possíveis de um conjunto previamente definido de hiperparâmetros. A escolha do Grid Search foi adequada neste caso porque o espaço de busca considerado é relativamente pequeno, permitindo testar todas as combinações possíveis de forma eficiente. Foram avaliadas diferentes configurações de dois hiperparâmetros importantes da árvore de decisão: o critério de divisão dos nós (criterion) e a profundidade máxima da árvore (max_depth). O objetivo dessa busca foi identificar uma configuração que equilibrasse capacidade de aprendizado e capacidade de generalização.

Comparação entre a Árvore Original e o Modelo Otimizado

Após a etapa de validação cruzada e busca de hiperparâmetros, foi possível comparar o desempenho do modelo otimizado com a versão inicial da árvore de decisão. A árvore original apresentava profundidade 26 e 928 folhas, indicando uma estrutura extremamente complexa. Após a otimização, o melhor modelo encontrado utilizou o critério gini e apresentou profundidade máxima igual a 5 e apenas 30 folhas, o que representa uma redução significativa na complexidade estrutural da árvore.

Essa redução demonstra o efeito da regularização por controle de profundidade, limitando a capacidade do modelo de criar regras excessivamente específicas para os dados de treinamento.

Robustez do desempenho

A robustez do modelo foi analisada a partir das métricas obtidas durante a validação cruzada. A precisão média obtida foi de 0.7696, com desvio padrão de aproximadamente 0.069. O coeficiente de variação foi de 9%, indicando uma variação moderada entre os folds. Esse resultado sugere que o modelo apresenta desempenho relativamente estável, sem depender excessivamente de uma única divisão dos dados.

O intervalo de confiança de 95% para a precisão foi estimado entre 0.7267 e 0.8126, indicando a faixa na qual o desempenho esperado do modelo provavelmente se encontra quando aplicado a novos dados.

Variação das métricas entre os folds

A análise das métricas em cada fold mostrou valores de precisão variando aproximadamente entre 0.678 e 0.891. Essa variação é esperada em processos de validação cruzada, já que cada divisão utiliza subconjuntos diferentes de dados para treinamento e validação. No entanto, a magnitude dessa variação permanece dentro de limites razoáveis, reforçando a ideia de que o modelo apresenta comportamento relativamente consistente.

Impacto da regularização na estrutura da árvore

A limitação da profundidade da árvore teve impacto direto na sua estrutura. Enquanto a árvore original possuía 26 níveis e 928 folhas, a árvore otimizada passou a ter 5 níveis e 30 folhas. Essa redução indica que o modelo passou a utilizar um conjunto muito menor de regras de decisão, tornando-se menos sensível a ruídos presentes nos dados de treinamento.

Como consequência, o modelo apresentou desempenho mais equilibrado entre os conjuntos de treino e teste, ambos com accuracy próxima de 0.86, o que sugere melhor capacidade de generalização em comparação com a árvore inicial.

Generalização do modelo

A proximidade entre os resultados obtidos nos conjuntos de treinamento e teste indica que o modelo otimizado apresenta boa capacidade de generalização. Diferentemente

da árvore inicial, que apresentava overfitting evidente, o modelo regularizado mantém desempenho semelhante em dados não observados durante o treinamento.

Interpretabilidade do modelo

Outro efeito importante da regularização foi a melhoria da interpretabilidade da árvore. Árvores muito profundas geram um grande número de regras complexas e difíceis de interpretar. Ao limitar a profundidade do modelo, a árvore resultante torna-se mais simples e mais fácil de analisar, permitindo identificar de forma mais clara quais variáveis e limites estão associados à previsão de churn.

Mínimos locais no treinamento de árvores

O processo de treinamento de árvores de decisão envolve escolhas sequenciais de divisões que buscam melhorar localmente a separação das classes. No entanto, essas decisões são gananciosas (greedy) e não garantem necessariamente a solução globalmente ótima. Dessa forma, diferentes configurações de hiperparâmetros podem levar a estruturas de árvore distintas, com desempenhos diferentes. O uso de validação cruzada e busca sistemática de hiperparâmetros ajuda a reduzir esse problema, permitindo selecionar uma configuração que apresente melhor desempenho médio em múltiplas divisões dos dados.

Discussão Aplicada

Do ponto de vista empresarial, o modelo otimizado de árvore de decisão apresenta características que podem torná-lo mais viável para apoiar decisões relacionadas à retenção de clientes. A redução da complexidade da árvore torna o modelo mais interpretável, permitindo identificar regras claras associadas ao risco de churn. Isso é particularmente importante em ambientes organizacionais, onde gestores precisam compreender os fatores que influenciam as previsões antes de tomar decisões estratégicas.

Além disso, o modelo otimizado apresentou desempenho semelhante entre os conjuntos de treinamento e teste, indicando maior estabilidade em comparação com a árvore inicial. Essa característica é fundamental em aplicações reais, pois modelos com forte overfitting podem gerar previsões pouco confiáveis quando aplicados a novos clientes.

Apesar disso, os resultados também evidenciam limitações relevantes. O modelo continua apresentando dificuldade em identificar corretamente clientes que realizam churn, o que reduz parcialmente seu valor operacional.

Modelo Ensemble: Random Forest

Nesta etapa foi utilizado um modelo Random Forest, um método ensemble baseado na combinação de múltiplas árvores de decisão. Diferentemente de uma árvore individual, o Random Forest constrói diversas árvores treinadas sobre subconjuntos diferentes dos dados e combina suas previsões, reduzindo a variância do modelo e aumentando sua estabilidade.

Validação cruzada e busca de hiperparâmetros

Para otimizar o modelo, foi realizada uma busca de hiperparâmetros utilizando Grid Search com validação cruzada estratificada. Foram avaliadas diferentes combinações de hiperparâmetros relevantes para o Random Forest, incluindo o número de árvores (n_estimators), a profundidade máxima das árvores (max_depth), e os parâmetros min_samples_split e min_samples_leaf, que controlam a complexidade das divisões realizadas pelas árvores.

A melhor configuração encontrada foi:

n_estimators = 100
max_depth = 5
min_samples_split = 5
min_samples_leaf = 1

Essa configuração indica um modelo relativamente controlado em termos de profundidade, o que contribui para reduzir o risco de overfitting.

Avaliação do modelo

No conjunto de treinamento, o modelo apresentou accuracy de aproximadamente 0.86. Para a classe 0 (clientes que permanecem no banco), o modelo apresentou precision de 0.85, recall de 0.99 e F1-score de 0.92. Já para a classe 1 (clientes que

realizam churn), o modelo apresentou precision de 0.89, recall de 0.34 e F1-score de 0.49.

No conjunto de teste, os resultados permaneceram praticamente iguais, com accuracy de 0.86. Para a classe 0, o modelo apresentou precision de 0.86, recall de 0.98 e F1-score de 0.92. Para a classe 1, os valores foram precision de 0.85, recall de 0.36 e F1-score de 0.51.

A proximidade entre os resultados de treinamento e teste indica que o modelo apresenta boa capacidade de generalização, sem sinais evidentes de overfitting.

Importância das variáveis

Uma das vantagens do Random Forest é a possibilidade de analisar a importância relativa das features no processo de decisão. Esse tipo de análise permite identificar quais variáveis possuem maior influência na previsão de churn, oferecendo insights relevantes para a compreensão do comportamento dos clientes.

A análise de importância das features no modelo Random Forest indica que Age (0.385) e NumOfProducts (0.318) são as variáveis mais influentes na previsão de churn. Em seguida aparecem IsActiveMember (0.097), Balance (0.056) e Geography_Germany (0.053), que também contribuem de forma relevante para a decisão do modelo.

Por outro lado, variáveis como Tenure (0.005), Satisfaction Score (0.0026), Card Type (0.0021) e HasCrCard (0.0011) apresentaram importância muito baixa, indicando que tiveram pouca influência nas decisões do modelo. Isso sugere que essas características possuem menor capacidade de distinguir entre clientes que permanecem no banco e aqueles que realizam churn dentro do dataset analisado.

Comparação com os modelos anteriores

Comparando os resultados com os modelos anteriores, observa-se que o Random Forest apresenta desempenho semelhante em termos de accuracy, mantendo valores próximos de 0.86. No entanto, sua principal vantagem está na maior estabilidade do modelo, decorrente da combinação de múltiplas árvores, o que reduz a sensibilidade a variações nos dados de treinamento.

Por outro lado, o modelo ainda apresenta dificuldade em identificar corretamente clientes que realizam churn, refletida nos valores relativamente baixos de recall para a classe positiva.

Complexidade e custo computacional

Embora o Random Forest ofereça maior robustez do que uma árvore de decisão individual, ele também apresenta maior custo computacional, já que o modelo precisa treinar múltiplas árvores. Além disso, a interpretabilidade do modelo é menor quando comparada a uma árvore única, pois a decisão final resulta da agregação de diversas árvores.

Discussão aplicada

Do ponto de vista empresarial, o modelo apresenta algumas vantagens relevantes para a previsão de churn. O modelo tende a produzir previsões mais estáveis e menos sensíveis a variações nos dados, o que pode aumentar a confiabilidade das estimativas de risco de cancelamento.

No entanto, o modelo também apresenta algumas limitações. Apesar de apresentar boa precisão geral, o desempenho na identificação de clientes que realmente realizam churn ainda é relativamente limitado.

Outro ponto importante é o custo computacional. Diferentemente de uma árvore de decisão simples, o Random Forest treina múltiplas árvores e combina suas previsões, o que aumenta o tempo de treinamento e o consumo de recursos computacionais. Embora esse custo seja geralmente aceitável para datasets de tamanho moderado, ele pode se tornar mais relevante em cenários com volumes de dados muito grandes ou em sistemas que exigem atualizações frequentes do modelo.

Por fim, embora o Random Forest ofereça melhor desempenho e maior estabilidade do que modelos mais simples, sua interpretabilidade é menor do que a de uma árvore de decisão individual, já que a previsão final resulta da agregação de várias árvores. Assim, sua aplicação prática deve considerar o equilíbrio entre ganho de desempenho, custo computacional e necessidade de explicabilidade das previsões para apoiar decisões empresariais.